

Отчёт. Assignment 2: CTC-декодирование и языковые модели

Курс: AI Talent Hub · Обработка речи

Выполнила: Денисова Карина

Акустическая модель: [facebook/wav2vec2-base-100h](#)

Тестовые наборы: LibriSpeech test-other (200 сэмплов), Earnings22 test (200 сэмплов)

Метрики: WER (Word Error Rate), CER (Character Error Rate)

1. Постановка задачи

Acoustic model [wav2vec2-base-100h](#) принимает сырой аудиосигнал и возвращает матрицу логитов $[T, V]$, где T — число временных шагов, $V = 32$ — размер словаря (символьный уровень: буквы + `<pad>` + `|`).

В рамках задания реализованы **4 стратегии CTC-декодирования**:

1. **Greedy decoding** — жадное декодирование (argmax по времени + CTC-collapse)
2. **Beam search** — лучевой поиск без языковой модели (CTC prefix beam search)
3. **Beam + shallow LM fusion** — лучевой поиск с интеграцией n-gram ЯМ на лету
4. **LM rescoring** — второй проход: переоценка N лучших гипотез с помощью ЯМ

Языковая модель: 3-gram KenLM, обученная на тексте LibriSpeech ([openslr.org/11](#)).

Скоринг с ЯМ:

```
score = log_p_acoustic + alpha * log_p_lm + beta * num_words
```

2. Task 1 — Greedy decoding

Жадное декодирование: на каждом шаге берётся символ с максимальной вероятностью, затем применяется CTC-collapse (удаление повторов и `<blank>`).

Датасет	WER	CER	Ref WER
LibriSpeech test-other	11.22%	3.81%	~10.4%
Earnings22 test	54.97%	25.58%	—

Результат на LibriSpeech близок к референсному. Высокий WER на Earnings22 объясняется **доменным сдвигом**: модель обучена на чистой студийной речи LibriSpeech, тогда как Earnings22 — это финансовые звонки с акцентами и специфической терминологией.

3. Task 2 — Beam search (без ЯМ)

Реализован **CTC prefix beam search**: на каждом шаге поддерживается `beam_width` лучших префиксов. Каждый префикс хранит пару (`p_blank`, `p_nonblank`) — вероятности последнего символа через пустой/непустой путь. Критически важный случай: при эмиссии того же символа, что уже стоит последним в префиксе, CTC-collapse реализуется через обновление `p_nonblank` для текущего префикса (не создаётся новый).




Рис. 1. WER и CER при разных значениях `beam_width` (LibriSpeech, 200 сэмплов). `beam_width=1` эквивалентен жадному декодированию; при увеличении до 10–50 качество улучшается, но с убывающей отдачей и значительным ростом времени вычисления.

Наблюдение: Beam search даёт небольшое улучшение над жадным декодированием (11.07% vs 11.22% WER). Время работы при `beam_width=50` примерно в 6× больше, чем при `beam_width=1`.

4. Task 3 — Temperature scaling

Перед softmax логиты делятся на температуру T :

- $T < 1$ — распределение «острее», модель увереннее
- $T > 1$ — распределение «мягче», что даёт больше влияния ЯМ




Рис. 2. WER при свипе температуры $T \in \{0.5, 0.8, 1.0, 1.2, 1.5, 2.0\}$ (жадное декодирование, LibriSpeech). На *in-domain* данных кривая практически плоская — акустическая модель хорошо откалибрована на LibriSpeech, поэтому изменение температуры не помогает.

Вывод: На LibriSpeech (in-domain) greedy + temperature не улучшает WER. Эффект температуры виден только при совместном использовании с ЯМ на out-of-domain данных (Task 7b).

5. Task 4 — Shallow LM fusion

Языковая модель интегрируется **на лету** во время beam search: при каждом появлении разделителя слов | запрашивается вероятность завершённого слова из KenLM. Оценка гипотезы:

$$\text{score} = \log_p_acoustic + \alpha * \log_p_lm + \beta * \text{num_words}$$

Проведён свип по $\alpha \in \{0.01, 0.05, 0.1, 0.5, 1.0, 2.0, 5.0\}$ и $\beta \in \{0.0, 0.5, 1.0, 1.5\}$.




Рис. 3. WER в зависимости от α и β (LibriSpeech, 200 сэмплов). При $\alpha=5.0$ ЯМ полностью перебивает акустику $\rightarrow$ WER=100%. Оптимальные значения в диапазоне $\alpha \in [0.1, 0.5]$, $\beta \in [1.0, 1.5]$.

Лучшая конфигурация: $\alpha=0.5$, $\beta=1.5 \rightarrow$ WER=11.05%

Датасет	WER	CER
LibriSpeech test-other	11.05%	3.78%
Earnings22 test	56.27%	25.56%

Вывод: LibriSpeech LM даёт небольшое улучшение на in-domain данных. На Earnings22 ЯМ **ухудшает** результат (56.27% vs 54.97% greedy) — LibriSpeech 3-gram не знает финансовой терминологии и штрафует правильные финансовые слова.

6. Task 5 — 4-gram LM

Используется 4-gram LM с openslr.org/11 ([4-gram.arpa](https://openslr.org/11/)). Слип по β при $\alpha=0.5$ (лучшее из Task 4):

beta	WER	CER
0.0	11.56%	3.88%
0.5	11.24%	3.82%
1.0	11.20%	3.81%
1.5	11.20%	3.80%

Сравнение 3-gram vs 4-gram (LibriSpeech, 200 сэмплов):

Модель	alpha	beta	WER	CER
3-gram	0.5	1.5	11.05%	3.78%
4-gram	0.5	1.0	11.20%	3.81%

Вывод: Вопреки ожиданиям, 4-gram LM дала результат **хуже** 3-gram (+0.15 п.п. WER). Причина — оба файла являются pruned-версиями: 3-gram.pruned.1e-7.агра прошёл агрессивную обрезку, что случайно улучшило совместимость с данным акустическим декодером. Кроме того, при **beam_width=10** 4-gram контекст не успевает раскрыться — для выигрыша от 4-gram нужен больший beam.

7. Task 6 — LM rescoring (второй проход)

Beam search генерирует **beam_width** лучших гипотез по акустике. Затем каждая гипотеза **полностью** переоценивается ЯМ:

$$\text{final_score} = \text{acoustic_log_prob} + \alpha * \text{lm_log_prob} + \beta * \text{num_words}$$

Аналогичный свип по alpha и beta.




Рис. 4. WER при LM rescoring (LibriSpeech, 200 сэмплов). Rescoring стабильнее shallow fusion при больших alpha: даже при alpha=5.0 WER не вырастает до 100%, так как нейросеть успела отфильтровать явно плохие гипотезы на первом проходе.

Лучшая конфигурация: $\alpha=0.01$, $\beta=1.5 \rightarrow \text{WER}=11.00\%$

7.1 Качественные примеры

Примеры из LibriSpeech, где SF или RS изменяют гипотезу относительно beam search:

#	REF	BEAM	SF	RS
4	...might do it he said...	...might doit he said...	...might do it he said... ✓	...might do it he said... ✓
8	...mister gurr father	...mister gurfather	...mister gur father	...mister gur father
5	... lobster boat coming...	... lobsterboat coming...	... lobsterboat coming...	... lobster boat coming... ✓

Полные примеры (10 шт.) сохранены в [results/task6_qualitative.txt](#).

Анализ:

- **Что исправляет ЯМ:** раздельное написание слитных слов (**doit**→**do it**, **lobsterboat**→**lobster boat**), разрыв слов на пробеле.
- **Что НЕ исправляет:** редкие собственные имена (**archy**, **gurr**, **risdon**) — они не встречаются в 3-gram LibriSpeech LM.
- **Shallow fusion vs rescoring:** SF иногда деградирует (меняет правильное на неправильное), RS стабильнее при малом α , поскольку N лучших акустических гипотез уже отфильтрованы.

8. Task 7 — Сравнительная таблица

Метод	LibriSpeech WER	LibriSpeech CER	Earnings22 WER	Earnings22 CER
Greedy	11.22%	3.81%	54.97%	25.58%
Beam search	11.07%	3.77%	54.94%	25.38%
Beam+LM shallow ($\alpha=0.5$, $\beta=1.5$)	11.05%	3.78%	56.27%	25.56%
Beam+LM rescore ($\alpha=0.01$, $\beta=1.5$)	11.00%	3.74%	55.33%	25.38%

Обсуждение доменного разрыва:

LibriSpeech WER ~11% против Earnings22 WER ~55% — разница обусловлена несколькими факторами:

1. **Словарный состав:** финансовые термины (**fiscal year**, **guidance**, **earnings per share**) отсутствуют в обучающих данных модели.
2. **Акустические условия:** Earnings22 — реальные телефонные звонки с шумом и акцентами.
3. **ЯМ:** LibriSpeech 3-gram LM только усугубляет Earnings22 (+1.3 п.п.) — она штрафует правильные финансовые слова как «не-слова».

9. Task 7b — Температурный свип на Earnings22




Рис. 5. WER при $T \in \{0.5, 1.0, 1.5, 2.0\}$ на Earnings22. Жадное декодирование (серая линия) практически не меняется — акустика ненадёжна вне зависимости от T . Beam+LM (синяя линия) немного улучшается при $T=0.5$ и деградирует при $T>1.0$.

Ответы на вопросы задания:

- **Помогает ли $T>1$ на Earnings22?** Нет. При $T>1$ распределение акустики размывается ещё сильнее, что позволяет ЯМ доминировать — но LibriSpeech ЯМ на финансовом тексте вредит, а не помогает.
- **Отличается ли от LibriSpeech?** Да. На LibriSpeech кривая temperature полностью плоская (модель откалибрована). На Earnings22 видна небольшая зависимость, потому что уверенность модели в out-of-domain данных ненадёжна — снижение T ($T=0.5$, «уверенная» модель) незначительно помогает ЯМ.

10. Task 8 — Финансовая языковая модель

Обучена 3-gram KenLM с помощью `kenlm lmplz` на корпусе `data/earnings22_train/corpus.txt` (~101 тыс. токенов, 5 701 уникальное слово).

Статистика обученной модели:

Порядок	N-gram	Дискаунт
1-gram	5 701	D=0.57
2-gram	42 688	D=0.76
3-gram	77 164	D=0.87

Размер модели: ~1 MB (trie без квантизации). Сохранена в `lm/financial-3gram.arpa`.

```
lmplz -o 3 --discount_fallback \
  < data/earnings22_train/corpus.txt > lm/financial-3gram.arpa
```

11. Task 9 — Сравнение LibriSpeech LM и финансовой LM

Две LM оценены на обоих тест-сетах с двумя лучшими методами декодирования.

LM	Метод	LS WER	LS CER	E22 WER	E22 CER
LibriSpeech 3-gram	beam_lm	11.22%	3.81%	55.39%	25.52%
LibriSpeech 3-gram	beam_lm_rescore	11.00%	3.75%	55.00%	25.41%
Financial 3-gram	beam_lm	11.27%	3.85%	52.74%	25.32%
Financial 3-gram	beam_lm_rescore	11.07%	3.78%	53.89%	25.22%

Ключевые наблюдения:

1. **Финансовая LM значительно улучшает Earnings22:** beam_lm 52.74% vs 55.39% у LibriSpeech LM (−2.65 п.п.). Финансовый словарь покрывает терминологию, которой нет в LibriSpeech LM.
2. **Финансовая LM слегка ухудшает LibriSpeech:** 11.27% vs 11.22% (+0.05 п.п.) — ожидаемый доменный штраф, незначительный.
3. **Rescoring стабильнее shallow fusion для обеих LM:** при rescoring WER ниже для LibriSpeech; на Earnings22 лучшую абсолютную точность даёт beam_lm с финансовой моделью (52.74%), а не rescoring (53.89%).
4. **Итоговый лучший результат на Earnings22:** Financial 3-gram + beam_lm = **52.74% WER** — улучшение на 2.23 п.п. относительно жадного декодирования (54.97%).

Ответы на вопросы задания:

- **Какая LM лучше in-domain (LibriSpeech)?** LibriSpeech 3-gram — WER=11.00% (rescore) vs 11.07% (Financial rescore).
- **Какая LM лучше out-of-domain (Earnings22)?** Financial 3-gram — WER=52.74% vs 55.39% у LibriSpeech LM.
- **Помогает ли domain-matched LM больше, чем большая общая?** Да: маленькая доменная 3-gram (77 К триграмм) превосходит большую LibriSpeech 3-gram на финансовом тест-сете. Доменное соответствие важнее объёма модели.

12. Итоговые выводы

1. **Greedy vs Beam search:** beam search даёт небольшое улучшение (+0.15 п.п. WER), но при beam_width=50 стоит в ~6× дороже по времени.

2. **Temperature scaling:** на in-domain данных (LibriSpeech) эффект незначителен — модель уже хорошо откалибрована. На out-of-domain (Earnings22) $T=0.5$ даёт небольшое улучшение.
3. **Shallow LM fusion:** при оптимальных α/β даёт улучшение на in-domain данных, но **ухудшает** результат на out-of-domain — LM обученная на LibriSpeech не знает финансовой терминологии.
4. **LM rescoring:** стабильнее shallow fusion при вариации α (не падает до WER=100% при высоком α), даёт наилучший результат на LibriSpeech: **WER=11.00%**.
5. **Доменный разрыв:** WER 11% → 55% при переходе LibriSpeech → Earnings22 подчёркивает критическую важность соответствия LM целевому домену.
6. **4-gram vs 3-gram LM (Task 5):** 4-gram (11.20%) неожиданно хуже 3-gram (11.05%) при `beam_width=10`. При малом beam 4-gram контекст не успевает раскрыться; выигрыш от 4-gram ожидается при `beam_width ≥ 50`.
7. **Доменная LM (Tasks 8–9):** финансовая 3-gram, обученная на 101 К токенов earnings22_train, снижает WER на Earnings22 с 55.39% до 52.74% (–2.65 п.п.) при beam_lm. На LibriSpeech деградация минимальна (+0.05 п.п.). **Вывод: доменное соответствие LM важнее её объёма.**